

①

ا) استفاده از $(r_\theta(x, y_w) - r_\theta(x, y_l)) \log \sigma$ باعث می شود به هنگام زیاد شدن اختلاف امتیاز $r_\theta(x, y_w)$ و $r_\theta(x, y_l)$ گرادیان به سمت صفر شدن برود زیرا $\log \sigma$ در مقادیر زیاد گرادیانش صفر می شود و به همین علت از زیاد شدن اختلاف امتیاز این دو جلوگیری می شود.

$$\text{objective}(\phi) = E_{(x, y) \sim D_{\pi_\phi^{RL}}} [r_\theta(x, y) - \beta \log \left(\frac{\pi_\phi^{RL}(y|x)}{\pi^{\text{SFT}}(y|x)} \right)] \quad (b)$$

$$+ \gamma E_{x \sim D_{\text{pretrain}}} [\log (\pi_\phi^{RL}(x))]$$

جهت حداکثر جمع reward برای جفت (x, y) به نوعی alignment مورد نظر.

$r_\theta(x, y) \rightarrow$

$\log \left(\frac{\pi_\phi^{RL}(y|x)}{\pi^{\text{SFT}}(y|x)} \right) \rightarrow$ برای جلوگیری از فراموشی زبان توسط مدل، تولید کردن جفت به معنی صحت حرکت کردن $\pi_\phi^{RL}(y|x)$ به نوعی باعث می شود فیلد از توزیع اولیه $\pi^{\text{SFT}}(y|x)$ optimization نموده نگردد.

$\log (\pi_\phi^{RL}(x)) \rightarrow$ برای جلوگیری از فراموش شدن کارایی مدل در شبکه های MLP که در pretraining وجود دارند.

ب) با توجه به اینکه $D_{\pi_\phi^{RL}}(x, y) \sim$ است ایستا و به نوعی دیتا static است، وابسته به صفر شدن π_ϕ^{RL} دارد، باعث $r_\theta(x, y)$ به هنگام متوقف شدن به صفر شدن می شود.

$$L_{\theta} = \mathbb{E}_{\pi_{\theta}} [G_t]$$

(d)

$$\nabla_{\theta} L_{\theta} = \nabla_{\theta} \mathbb{E}_{\pi_{\theta}(\tau), \tau} [G_t] = \nabla_{\theta} \int \pi_{\theta}(\tau) G_{\tau} d\tau$$

$$= \int \nabla_{\theta} \pi_{\theta}(\tau) G_{\tau} d\tau = \int \pi_{\theta}(\tau) \frac{1}{\pi_{\theta}(\tau)} \nabla_{\theta} \pi_{\theta}(\tau) G_{\tau} d\tau$$

$$= \int \pi_{\theta}(\tau) \nabla_{\theta} \log \pi_{\theta}(\tau) G_{\tau} d\tau$$

$$= \mathbb{E}_{\pi_{\theta}, \tau} [\nabla_{\theta} \log \pi_{\theta}(\tau) G_{\tau}]$$

$$= \mathbb{E}_{\pi_{\theta}, \tau} \left[\left(\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right) G_t \right]$$

(e)

برای مقایسه L نیاز هست که توزیع $\pi_{\theta}^{PL}(y|m)$ ، $\pi^{SFT}(y|m)$ را برای m نقاط m بنویسیم اما
ما این مقادیر را برای m نقاط نداریم به همین علت باید به نمونه گیری این KL را
تخمین زد. (نمونه گیری $\pi^{PL}(y|m)$)

$$D_{KL}(q||p) \approx \frac{1}{N} \sum_{i=1}^N \log \frac{q(m_i)}{p(m_i)}, m_i \sim q(m)$$

این تخمین unbiased هست اما Variance زیادی دارد.

$$r = \frac{p(m)}{q(m)} \Rightarrow K_1 = -\log r$$

به صورت شش می توان گفت که در
این تخمین به طور متوسط نصف نمونه ها متعلق به نمونه
در حالی که L متعلق نمی شود. پس Variance
بالایی دارد. اما تخمین زیر مقادیر متعلق ندارد پس Variance کمتری دارد.

$$D_{KL}(q||p) \approx \frac{1}{N} \sum \frac{1}{2} [\log q(n_i) - \log p(n_i)]^2, \quad n_i \sim q(n)$$

این تخمینگر biased است و Variance کمی است.

$$K_2 = \frac{1}{2} (\log^2 r)$$

$$E_q[K_2] = E_q\left[\frac{1}{2} \log^2 r\right] \quad \left. \begin{array}{l} \text{f-divergence} \\ f = \frac{1}{2} \log^2 n \end{array} \right\} \quad \begin{array}{l} f(n) = -\log n \\ f'(1) = 1 \end{array}$$

تخمینگر بی‌سازگاری:

$$D_{KL}(q||p) \approx \frac{1}{N} \sum_{i=1}^N \exp\left\{ \frac{1}{2} [\log q(n_i) - \log p(n_i)]^2 - 1 - \frac{[\log q(n_i)]^2}{-2 \log p(n_i)} \right\}$$

$$\max_{\theta} E_{n \sim D, y \sim \pi_{\theta}(y|m)} [r_{\phi}(n, y)] - \beta D_{KL}[\pi_{\theta}(y|m) \parallel \pi_{ref}(y|m)] \quad (2) \quad (a)$$

Langrangian :

$$\max_{\theta} E_{n \sim D, y \sim \pi_{\theta}(y|m)} [r_{\phi}(n, y) - \beta D_{KL}(\pi_{\theta}(y|m) \parallel \pi_{ref}(y|m))] + \lambda (1 - \int \pi_{\theta}(y|m) p(n) dn dy)$$

$$= \int \left(r_{\phi}(n, y) - \beta \log \frac{\pi_{\theta}(y|m)}{\pi_{ref}(y|m)} \right) \pi_{\theta}(y|m) p(n) dn dy$$

$$+ \lambda \left(1 - \int \pi_{\theta}(y|m) p(n) dn dy \right)$$

$$\frac{\partial L}{\partial \pi_{\theta}(n|y)} = \left(r_{\phi}(n, y) - \beta \log \frac{\pi_{\theta}(y|m)}{\pi_{ref}(y|m)} \right) p(n) - \beta p(n) - \lambda p(n) = 0$$

$$\Rightarrow \frac{\pi_{\theta}(y|m)}{\pi_{ref}(y|m)} = e^{\frac{1}{\beta} r_{\phi}(n, y) - \frac{\lambda + \beta}{\beta}}$$

$$\Rightarrow \pi_{\theta}(y|m) = e^{-\frac{\lambda + \beta}{\beta}} \pi_{ref}(y|m) e^{\frac{1}{\beta} r_{\phi}(n, y)}$$

$$= \frac{1}{Z(n)} \pi_{ref}(y|m) e^{\frac{1}{\beta} r_{\phi}(n, y)}$$

المعادلة

(b)

$$\pi_{\theta}(y|m) = \frac{1}{z(m)} \pi_{ref}(y|m) e^{\frac{1}{\beta} r_{\theta}(m,y)}$$

خواص

$$\log \frac{z(m) \pi_{\theta}(y|m)}{\pi_{ref}(y|m)} = \frac{1}{\beta} r_{\theta}(m,y)$$

$$\Rightarrow r_{\theta}(m,y) = \beta \log z(m) + \beta \log \frac{\pi_{\theta}(y|m)}{\pi_{ref}(y|m)} \quad (1)$$

$$L_{\theta}(r_{\theta}, D) = -E_{(n, y_w, y_L) \sim D} [\log \sigma(r_{\theta}(n, y_w) - r_{\theta}(n, y_L))] \quad (2)$$

$$(1), (2) \Rightarrow L_{D\theta}(\pi; \pi_{ref}) = -E_{n, y_w, y_L \sim D} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|m)}{\pi_{ref}(y_w|m)} - \beta \log \frac{\pi_{\theta}(y_L|m)}{\pi_{ref}(y_L|m)} \right) \right]$$

(c)

$$\nabla_{\theta} L_{D\theta}(\pi_{\theta}; \pi_{ref}) = \nabla_{\theta} E_{n, y_w, y_L \sim D} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|m)}{\pi_{ref}(y_w|m)} - \beta \log \frac{\pi_{\theta}(y_L|m)}{\pi_{ref}(y_L|m)} \right) \right]$$

$$= -E_{n, y_w, y_L \sim D} \left[\frac{\sigma'(u)}{\sigma(u)} \nabla_{\theta} \left(\beta \log \frac{\pi_{\theta}(y_L|m)}{\pi_{ref}(y_L|m)} - \beta \log \frac{\pi_{\theta}(y_w|m)}{\pi_{ref}(y_w|m)} \right) \right]$$

$$= -E_{n, y_w, y_L \sim D} \left[\beta \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|m)}{\pi_{ref}(y_w|m)} - \beta \log \frac{\pi_{\theta}(y_L|m)}{\pi_{ref}(y_L|m)} \right) \left[\nabla_{\theta} \log \pi(y_w|m) - \nabla_{\theta} \log \pi(y_L|m) \right] \right]$$

Reward مربوط به مدل زنجیره ای $\pi_\theta(y|n)$ و مدل زنجیره ای reference
 بین $\pi_{ref}(y|n)$ که بتوان به دست مستقیم به دست نیاید
 . Optimize Policy, Reward function

$$\beta \sigma \left(\beta \log \frac{\pi_\theta(y_w | n)}{\pi_{ref}(y_w | n)} - \beta \log \frac{\pi_\theta(y_l | n)}{\pi_r(y_l | n)} \right) :$$

$$\nabla_\theta \log \pi(y_w | n) :$$

جهت افزایش likelihood خروجی مناسب y_w

$$-\nabla_\theta \log \pi(y_l | n) :$$

جهت کاهش likelihood خروجی نامناسب y_l